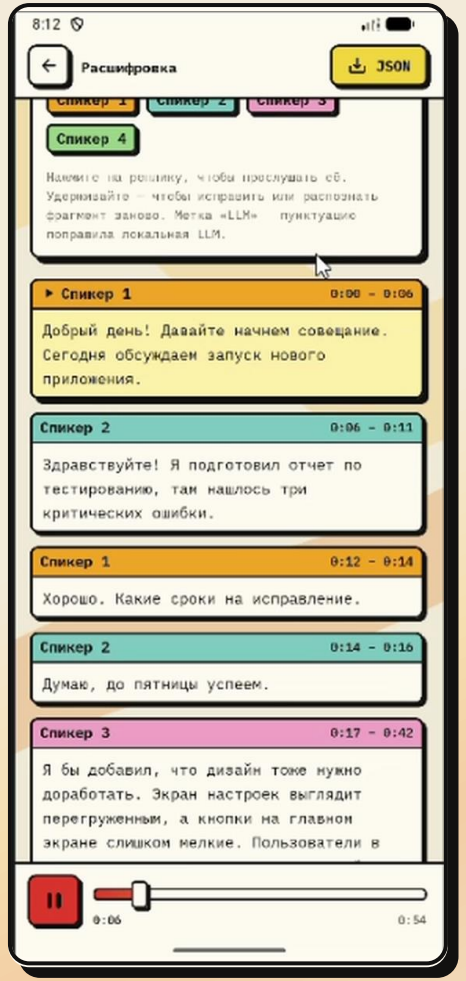
RECO

нейро-стенографист для Android

Расшифровка разговоров с разделением по говорящим и временными метками — полностью на телефоне, без интернета.

Nuclear IT Hack 2026 · Финал · Студия аналитики 258



01 · ЗАДАЧА

Что требовалось сделать

Обязательные требования — все выполнены

- ✓ работает под Android
- ✓ использует локальную LLM
- ✓ импортирует запись из памяти устройства
- ✓ преобразует речь в текст
- ✓ определяет и разделяет говорящих
- ✓ ставит временные метки репликам
- ✓ показывает расшифровку
- ✓ экспортирует результат в JSON

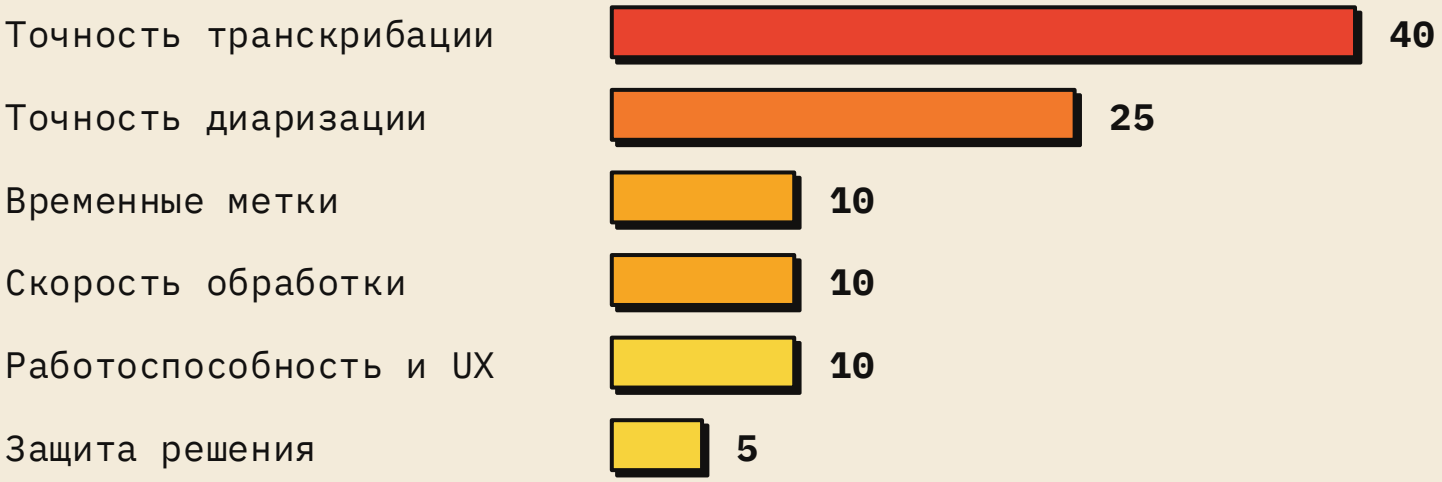
Запрещено

- облачные API и внешние сервисы
- вычисления на сервере или ПК
- подмена готовой расшифровкой

Проверка: эксперты ставят APK, загружают 3 записи диалогов и считают WER и RTF.

02 · КРИТЕРИИ

Как оценивают — и что мы из этого вывели



Наш вывод

65 из 100 — точность текста и говорящих.

Значит, ничто не должно ухудшать WER — даже LLM.

Скорость и память — второй приоритет.

03 · РЕШЕНИЕ

Всё работает на телефоне

0

разрешений на интернет в манифесте — данные физически не уходят с устройства

5

моделей внутри приложения: речь, говорящие, паузы, пунктуация

1,1 ГБ

APK со всеми моделями — работает в авиарежиме с первого запуска

04 · КОНВЕЙЕР

От записи до JSON — 9 шагов

01
Декодирование
любой формат → 16 кГц моно

02
Предобработка
без смещения, громкость до ×30

03
Диаризация
pyannote + CAM++

04
Разрез по паузам
Silero VAD, пауза от 0,2 с

05
Уточнение
второй проход по голосам

06
Нарезка
куски до 28 с

07
Распознавание
Parakeet TDT 0.6B

08
Пунктуация
Qwen3-0.6B + проверка слов

09
Реплики → JSON
speaker, start, end, text

Модели грузятся **по очереди** и выгружаются после своего этапа

05 · МОДЕЛИ

Что внутри и почему именно это

Этап	Модель	Размер	Почему
Распознавание	NVIDIA Parakeet TDT 0.6B v3, int8	670 МБ	RU + EN, сам ставит пунктуацию
Пунктуация	Qwen3-0.6B, int4 (LiteRT-LM)	~330 МБ	знает русский, быстрая на CPU
Смены говорящих	pyannote segmentation 3.0, int8	1,5 МБ	находит речь и смены говорящего
Отпечаток голоса	3D-Speaker CAM++	28 МБ	точный при малом размере
Паузы	Silero VAD	0,6 МБ	точно находит паузы между фразами

Все модели — через sherpa-onnx 2.0.1 и LiteRT-LM; та же версия работает в наших тестах на Python, поэтому тесты повторяют приложение один в один.

06 · РЕШЕНИЕ №1

Свой второй проход для говорящих

Проблема

pyannote смотрит окнами по 10 с и на шуме склеивал реплики разных людей: «Согласен» доставалось лишнему, пятому говорящему.

Что сделали

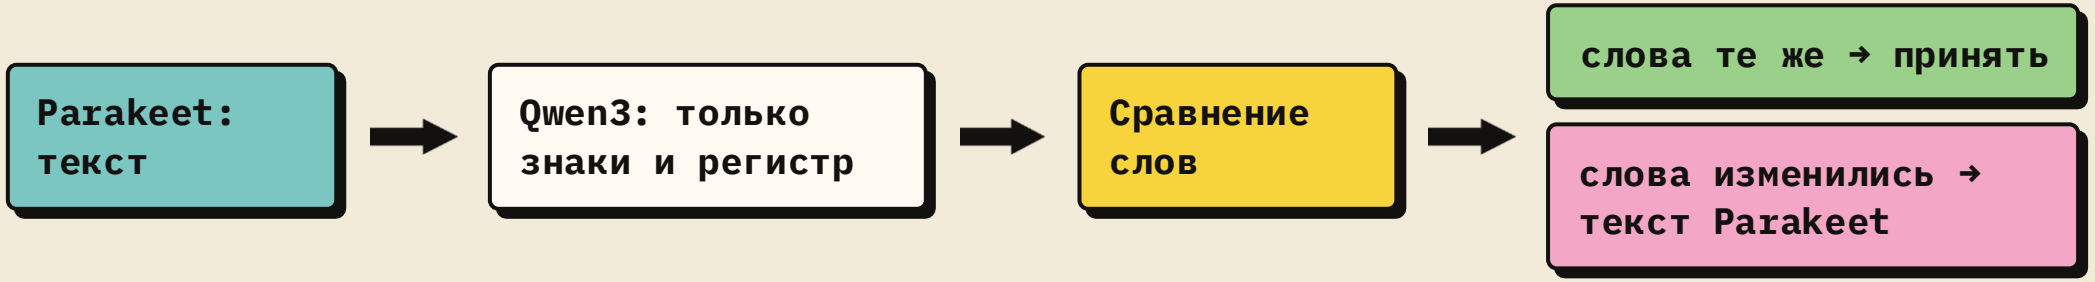
- режем сегменты посередине пауз (Silero VAD)
- заново считаем отпечаток голоса и сливаем похожих говорящих

Шумная запись, SNR 5 дБ

Показатель	Было	Стало
Точность диаризации	88,5%	99,0%
Говорящих (эталон 4)	5	4
Ошибка начала / конца	1272 / 1190 мс	105 / 211 мс
Реплик (эталон 8)	6	8

07 · РЕШЕНИЕ №2

Локальная LLM — под жёсткой проверкой слов



Условный пример

вход: думаю до пятницы успеем
LLM: Думаю, до пятницы успеем. → **принято**
LLM: Думаю, к пятнице успеем. → **отклонено**

WER =

до и после LLM — на всех наборах

2–5%

ответов принято, 84–93% отклонено проверкой

08 · РЕШЕНИЕ №3

Надёжность на обычном телефоне

Без интернета

в манифесте нет разрешения INTERNET

Модели по этапам

в памяти только модели текущего этапа

Работа в фоне

foreground-сервис: свернули — обработка идёт

Тихий микрофон

громкость ×0,03 и смещение → тот же WER 0,9%

Данные на устройстве

без резервного копирования, экспорт по выбору

Сбой LLM не страшен

расшифровка всё равно готова

09 · РЕЗУЛЬТАТЫ

Тестовый диалог: 4 голоса, 8 реплик, 54 с

0,9%
WER на чистой записи (1,7% в CI)

99%
точность диаризации

4/4
говорящих найдено автоматически

23 мс
средняя ошибка начала реплики

⚠ С шумом (SNR 5 дБ): WER 10–12%, диаризация по-прежнему 99%, границы реплик 105 / 211 мс.

10 · НАСТОЯЩАЯ РЕЧЬ

open_stt: 900 фраз с ручной разметкой

Набор (300 фраз)	Что	WER	WER после LLM	LLM: исправлено / отклонено
asr_calls_2_val	телефон	33,2%	33,2%	14 / 253
public_youtube700_val	YouTube	23,3%	23,3%	6 / 278
buriy_audiobooks_2_val	аудиокниги	20,8%	20,8%	11 / 256

Почему не 1%?

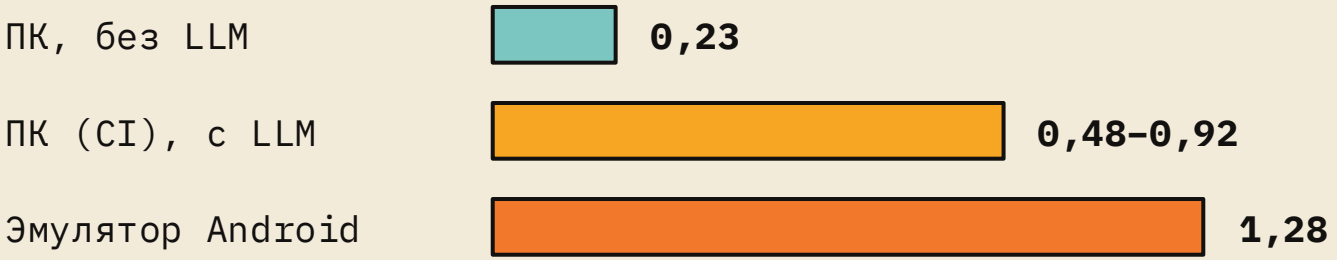
Это живая речь: телефонная связь, шум, разговорные обороты. Тестовый диалог — синтез.

Главное

WER после LLM совпадает с WER распознавания — проверка слов работает и на реальных данных.

11 · СКОРОСТЬ

RTF — время обработки / длительность



RTF меньше 1 — быстрее реального времени. На реальном телефоне скорость не замеряли.

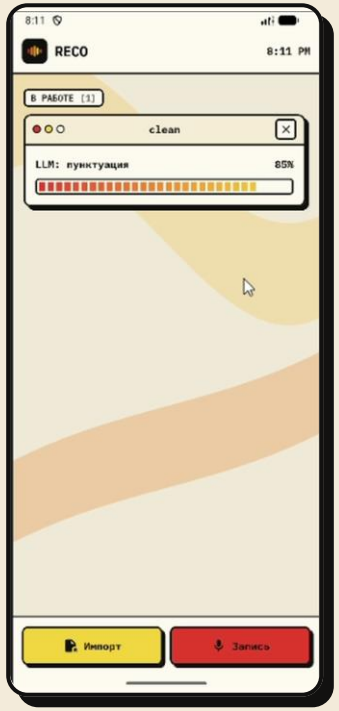
Узкое место

Самый медленный этап — LLM: RTF ≈ 0,8 против ≈ 0,1 у Parakeet.

Время и RTF каждой записи видны в окне «Сведения».

12 · ПРИЛОЖЕНИЕ

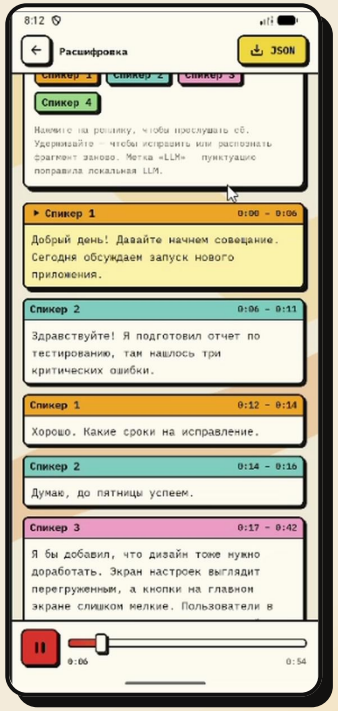
Ретро-интерфейс, всё под рукой



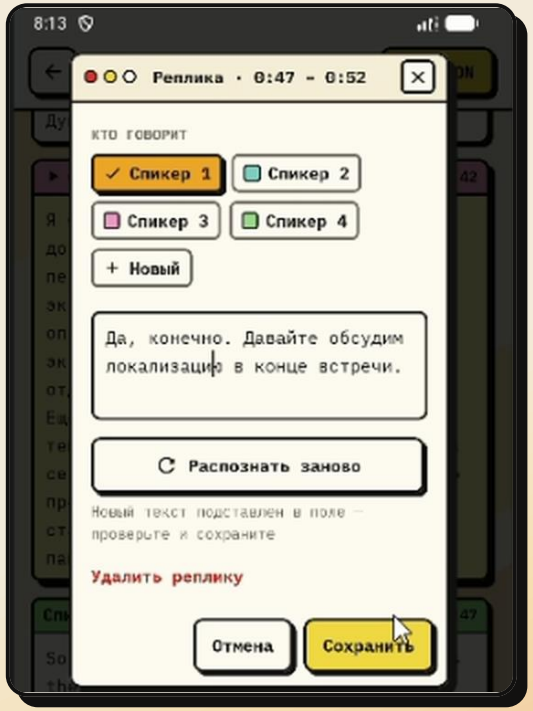
Прогресс по этапам



RTF и итоги LLM



Реплики и плеер



Правка и «Распознать заново»

13 · УРОВНИ ЗАДАНИЯ

Базовое — полностью, средний — полностью

Базовое

- ✓ работающий APK
- ✓ импорт аудиофайла
- ✓ локальная LLM
- ✓ распознавание речи
- ✓ автоматическая диаризация
- ✓ временные метки
- ✓ отображение и экспорт

Средний

- ✓ предобработка аудио
- ✓ фильтрация пауз (VAD)
- ✓ устойчивые говорящие
- ✓ восстановление пунктуации
- ✓ прогресс обработки
- ✓ переход к реплике в плеере

Ultra Pro Max

- ✓ правка и повторная обработка
- ✓ оптимизация памяти
- ⚠ шум и тихие записи — частично
- ⚠ короткие реплики — частично
- — одновременная речь — нет
- — аппаратное ускорение — нет

14 · ЧЕСТНО

Ограничения и что дальше

Ограничения

- перекрытия речи не разделяются
- на сильном шуме WER до ~12%
- LLM почти всегда отклоняется
- APK 1,1 ГБ, на устройстве ~2,5 ГБ

Следующие шаги

- ✓ дообучить Parakeet на русской телефонной речи
- ✓ разделять одновременную речь
- ✓ ускорение на NPU / GPU телефона
- ✓ LLM крупнее или дообученная на пунктуации



Спасибо!

github.com/KiraPankov/RECO

APK и видео демонстрации — в релизе v1.0.0